

Projet SY09 : Compte-Rendu d'analyse

Elise MAISTRE, Ikram DAMA

19 juin 2023

1 Introduction

Notre projet se porte sur le jeu de données *Ask a Manager Salary Survey* ayant été réalisé à partir d'un sondage sur la population entre avril et mai 2021. Ce set de données comprend 18 variables décrivant 26 232 observations, ces variables sont à la fois le salaire annuel, mais également des données qui caractérisent l'individu. L'objectif de notre projet sera d'explorer et d'analyser ces données pour pouvoir les utiliser ultérieurement.

Pour commencer, nous effectuerons une exploration des données pour découvrir et comprendre ces données afin de mieux les utiliser. Nous examinerons la structure des données, les valeurs manquantes éventuelles, les statistiques descriptives et les distributions des variables. Nous utiliserons des techniques de visualisation et de résumé statistique pour obtenir des informations.

2 Présentation des données

TABLE 1 – Présentation des données et descriptions

Données	Description
timestamp	Date de réponse (avril/mai 2021)
how old are you	Age de l'individu
industry	Domaine du métier exercé
job title	métier exercé (titre)
additional context on job title	Informations supplémentaires
annual salary	Salaire annuel
other monetary comp	Primes
currency	Monnaie de conversion
currency other	Autre monnaie de conversion
additional context on income	Autres informations
country	Pays de l'individu
state	Etat des Etats-Unis de l'individu
city	Ville de l'individu
overall years of professional experience	Expériences professionnelles
years of experience in field	Exp professionnelle dans le domaine
highest level of education completed	Plus haut niveau d'étude
gender	Genre
race	Origine

Nos données comportent donc 18 variables qui ne sont pas toutes utilisables. Ces données sont présentées dans

les tableaux ci-joint avec leur proportion. La plupart de ces données sont donc qualitatives ainsi un gros travail de transformation des données sera à prévoir.

TABLE 2 – Présentation des données de l'étude : leur quantité et leur qualité

Données	Quantité	Défaut / Qualité
timestamp	complète	inutile
how old are you	complète	7 catégories croissantes
industry	complète	nombreuses catégories différentes
job title	presque complète	nombreuses catégories différentes
additional context on job title	presque vide	non traitable
annual salary	complète	variable principale
other monetary comp	complète	beaucoup de valeurs à 0
currency	complète	grande majorité du dollar
currency other	presque vide	inutilisable
additional context on income	presque vide	inutilisable
country	complète	information à retravailler
state	presque complète	cas uniquement USA
city	complète	inutilisable
overall years of professional experience	complète	8 catégories croissantes
years of experience in field	complète	8 catégories croissantes
highest level of education completed	complète	7 possibilités
gender	complète	Déséquilibré
race	complète	Déséquilibré

La plupart des informations ont été cochées par l'utilisateur et correspondent à une catégorie prédéfinie ce qui permet l'analyse ultérieure. Ces données présentées ne pourront pas toutes être utilisées dans la suite de l'étude, certaines nécessitent un long travail de traitement et d'autres sont trop peu présentes pour être utilisées. On a pu remarquer que certaines données présentent des disparités et des déséquilibre qu'il faudra prendre en compte dans l'étude.

3 Problématique

A partir de ces données nous pouvons établir notre problématique pour cette étude. Elle consistera à tenter de prédire le salaire annuel des individus en utilisant les variables qui auront un impact sur cette donnée cible. A partir de ces différentes caractéristiques nous essayerons de déterminer le salaire et testeront nos résultats après avoir entraîné différents modèles sur une autre partie. Nous cherchons donc à savoir s'il serait possible, à partir de simples caractéristiques sur des individus et sur leur métier d'établir un rapprochement et même une prédiction sur leur salaire annuel.

4 Analyse exploratoire

A partir d'une première analyse on remarque que les données ne sont pas homogènes et révèlent certaines disparités. Les données concernent en grande majorité des personnes habitants aux Etats-Unis avec plus de 82% des observations, principalement des femmes, blanches. On peut le voir avec la figure ci-dessous qui illustre ces différences de résultats. Nous pourrions tout de même évaluer certaines caractéristiques utiles pour notre étude, en conservant certaines de ces catégories.




FIGURE 1 – Répartition selon le genre et l'origine

Nous décidons donc de restreindre notre analyse sur les données des Etats-Unis, au vu des différences qui peuvent exister entre les salaires des différents pays et dans la grande majorité des réponses proviennent des Etats-Unis. Il est alors intéressant d'observer la représentation des salaires à partir des états entrés et de définir s'il y aurait un potentiel lien avec le salaire en fonction de la position. Nous avons pu représenter cette information en utilisant une carte visuelle. Pour cela, les coordonnées json des 51 états ont été retrouvées en ligne et visionnées selon la médiane pour chacun des états. On observe certaines disparités sur la carte ci-dessous.




FIGURE 2 – Carte de la médiane des salaires par états (avec plotly)

Nous avons voulu améliorer ces résultats en réalisant une classification hiérarchique ascendante sur ces états pour regrouper les états selon leur proximité et leur salaire.

On remarque que les 4 zones correspondantes sont en effet à proximité avec des Salaires plu ou moins proche. Il est tout de même difficile de réaliser une classification avec uniquement ces données.




FIGURE 3 – Dendrogramme issu de la CAH des états selon leur salaire médian et leur position

Une autre analyse a pu être réalisée, elle consistait en l'observation de la variable liée au niveau d'étude maximal atteint par l'individu. On cherche à savoir si cette variable serait nécessaire à la prédiction du salaire.




FIGURE 4 – Fonction ECDF du salaire selon le niveau d'étude maximal




FIGURE 5 – Zoom de la fonction précédente sur une portion plus faible et légende

L'ECDF est une fonction qui attribue une probabilité cumulée à chaque valeur dans un ensemble de données, en indiquant quelle proportion des valeurs est inférieure ou égale à cette valeur donnée. Le tracé ECDF est donc utile pour visualiser la distribution empirique des données et observer la proportion cumulative des valeurs. Cette méthode est ici la meilleure pour rendre compte de la proportion de salaire selon le niveau d'étude atteint. On peut remarquer que le niveau atteint est bien croissant, on a au départ High School et Some College sans diplôme qui semblent très proche avec un léger décalage puis College Degrees, ensuite Master Degrees et finalement PhD et Professional Degree qui sont les deux niveaux les plus hauts d'étude qui peuvent être atteints aux Etats-Unis.

La valeur aucun peut-être considérée comme aberrante car correspond aux personnes n'ayant pas rempli cette question, nous ne l'utiliserons pas pour prédire le salaire.

On peut ainsi comprendre que la variable étude est significative dans la prédiction du salaire

5 Normalisation du salaire

On visualise la distribution des salaire à l'aide d'une boîte à moustaches présentée ci-dessous.

On remarque que cette distribution est asymétrique et présente des valeurs aberrantes. Nous pourrions donc supprimer les valeurs aberrantes pour d'obtenir une meilleure estimation de la tendance centrale de la distribution. Les salaires sont très grands et il peut-être intéressant de considérer plutôt le logarithme népérien du salaire pour la réduction de l'asymétrie : Cela peut faciliter l'interprétation des relations et des effets dans le cadre de la régression linéaire, qui suppose une relation linéaire entre les variables et la stabilisation de

la variance. Cela peut-être bénéfique pour les modèles de régression linéaire, qui supposent également une variance constante des résidus. Cette méthode a pu être appliquée et a permis d'améliorer les performances des modèles de prédiction.




FIGURE 6 – Distribution du salaire

6 Prédiction des salaires

6.1 Préparation des données

6.1.1 Variables sous forme de chaîne de caractère

Les variables tapées en entrée par l'utilisateur sont nombreuses et difficiles à traiter. Nous avons par exemple dû traiter chacun des cas pour utiliser le pays et ne conserver que les Etats-Unis. Par la suite, nous avons choisi de ne pas prendre en compte la ville au vue des grandes disparités d'écriture et du plus grand nombre de possibilité.

Quelques variables qualitatives de notre jeu de données comportent plusieurs valeurs très peu utilisées. Ces rares valeurs peuvent causer du surapprentissage et du bruit au niveau du modèle de prédiction. Elles peuvent également être uniquement présentes dans l'ensemble de test ou celui d'entraînement.

Pour résoudre ce problème, on calcule la fréquence des valeurs prises par la variable et l'on essaie d'estimer le nombre de valeurs à retenir. Ensuite, on crée une nouvelle valeur nommée others qui remplacera les valeurs considérées comme étant rares.

On a pu en effet appliquer cette transformation pour la variable *industry* qui d'après le sondage initial contenait 25 cases à cocher et une case autre pour rajouter le champs voulu de manière manuscrite. On a donc conservé les valeurs les plus présentes qui se trouvaient être les choix à cocher.




FIGURE 7 – Catégorie de métier les plus présents

Concernant la variable job title qui représente le nom du métier nous avons décidé de la traiter, en effet nous avons considéré cette variable comme essentielle à la prédiction du salaire. Puisque le métier et la catégorie qu'il représente peut nous informer sur le status de la personne dans l'entreprise et donc sur son salaire. Nous avons pu chercher les occurrences de certains mots (parmi ceux très présents) pour les associer en plusieurs colonnes, les mots retenus sont les suivants et ont été choisis selon leur pertinence et leur présence, en voici des exemples : director, engineer, assistant, senior, manager, specialist, teacher, ...

D'autres mots ont été concaténés en catégories de mots rapportant à différents sous-groupes, comme l'informatique, au monde de la juridiction ou encore des ressources humaines.

Ils ont été choisis après avoir analysé leur présence dans les noms ayant le plus d'occurrence (après avoir tout transformé en minuscule pour ne pas être sensible à la casse). On peut voir les catégories ayant le plus d'occurrence précédemment, c'est ce type de graphe qui a permis l'élaboration des différentes catégories.

Il est à noter que nous avons expérimenté l'utilisation du target encoding pour ces deux variables, mais nous avons constaté que cela entraînait du surapprentissage. Par conséquent, nous avons décidé de ne pas l'utiliser pour ces variables dans notre approche finale.

6.1.2 One Hot Encoding

La grande majorité des données ont été transformées par la méthode du One hot Encoding ou l'encodage un parmi n. Cet encodage permet de traiter des données quantitatives, de conserver les catégories voulues, en ajoutant un 1 dans le cas de la présence et un 0 dans le cas contraire. Ainsi on pu sélectionner différentes variable

pour être traduites ainsi. On a décidé de conserver les états au vu de la carte précédente qui permettait de conclure sur leur importance dans la prédiction des salaires. Les 51 états ont donc été encodés ainsi, chacun ayant un 1 quand ils sont le correspondant et dans tous les autres cas un 0.

Nous avons également décidé de conserver les variables de genre et d'origine qui consistue encore aujourd'hui des différences de salaires. Certaines études établissent des disparités selon le genre de l'individu et également selon l'éthnie auquel il appartient. Ces valeurs ont été encodés, avec pour le genre 3 catégories : homme, femme et autre et pour l'origines les 7 catégories de départs.

6.1.3 Codage additif

D'après l'analyse exploratoire, nous avons pu démontrer l'importance du niveau d'étude atteint pour la prédiction du salaire. Nous avons voulu retranscrire au mieux ces caractéristiques et nous avons choisi la méthode additive pour cela. En effet, les 5 premières catégories sont rangés dans un ordre où l'individu aura fait les précédentes avant d'y arriver. Concernant PhD et Professional Degree nous avons dû les séparer et modifier la méthode sur la fin car les deux ne sont pas réalisable l'un après l'autre mais c'est un choix entre l'un ou l'autre en fin d'étude.

Nous avons d'abord testé la méthode d'encoding avec ces variables puis cette méthode additive et nous avons obtenus de meilleurs résultats pour tous les modèles avec la méthode additive, que nous avons donc sélectionné.

6.1.4 Transformation des variables d'intervalles d'années

Certaines variables étaient présentes sous forme de catégories, c'est le cas de l'âge, des années d'expérience professionnelles dans le domaine exercé et total. Ces 3 catégories sont des intervalles d'années et peuvent être traitées différemment. Tout d'abord, elles sont essentielles à la prédiction du salaire, en effet, l'âge et l'expérience sont des facteurs d'augmentation de salaire puisque souvent raison de plus grandes connaissances. La variable d'expérience professionnelle dans le domaine est également très importante car présente dans le CV et souvent raison d'embauche et d'augmentation.

Nous avons donc transformé ces intervalles selon la moyenne de chacun d'eux, au centre de leur borne.

Ces données sont ensuite utilisées comme quantita-

tives et ont pu être normalisées avec MinMaxScalar sans modifier les résultats de régression.

6.2 Séparation des données en ensemble d'entraînement et de test

Dans notre situation, on sépare nos données aléatoirement en ensembles d'entraînement et de test car il n'y a pas de dépendance entre les observations.

6.3 Classification

Nous avons tout d'abord, voulu expérimenter la classification avant de se lancer dans la régression pour prédire les salaires des individus. Nous avons transformé les salaires en différents paliers, en utilisant 5 paliers : inférieur à 25.000, entre 25.000 et 50.000, entre 50.000 et 75.000, entre 75.000 et 150.000 et supérieur à 150.000 dollars. Ces paliers ont permis la classification en considérant les variables ainsi sélectionnées.

Nous avons choisi de tester sur deux modèles le GradientBoostClassifier et le DecisionTreeClassifier de la librairie scikit-learn. Ces modèles ont été entraînés sur une partie d'entraînement, représentant 80% des données et testées sur les 20% restants.

Les résultats sont différents et intéressants. En effet, on obtient de bien meilleurs résultats pour le Gradient Boost Classifier que pour le Decision Tree Classifier. Les résultats peuvent être présentés de deux manières : tout d'abord comme un échantillon de résultats pour comparer nous même de la réussite et ensuite comme un score de classification.

TABLE 3 – Résultats de prédiction de la classification Gradient Boost Classifier

prédiction	réel
aise	aise
tres aise	aise
moyen	aise
aise	aise
pauvre	moyen
aise	tres aise
moyen	moyen

TABLE 4 – Résultat des exemples de classification

Gradient Boost Classifier	Decision Tree Classifier
58.16%	49.85%

On remarque que les résultats de classification sont plutôt bon, mais on aimerait maintenant prédire un salaire plus précisément et déterminer les variables d'importance, de plus on aimerait définir notre modèle selon des caractéristiques particulières. Pour cela, on va donc réaliser une régression.

6.4 Régression

Nous avons décidé d'appuyer d'avantage notre étude sur la régression, au vue des plus grande possibilité qu'elle nous apporte. Nos données ont donc été encodées pour la régression et y sont donc utilisées telles que décrites ci-dessus.

6.4.1 Les modèles

Nous avons sélectionné trois modèles pour notre régression : Linear Regression, Random Forest Regressor et XGB Regressor. Ces trois modèles sont intéressant à traiter car utilisés pour différents cas. La régression linéaire cherche à établir une relation linéaire entre les variables pour prédire les valeurs de la variable cible. Le modèle de forêt aléatoire utilise plusieurs arbres de décision pour effectuer des prédictions et peut gérer des données complexes avec des relations non linéaires. Finalement le modèle XG Boost utilise l'algorithme du gradient boosting pour améliorer progressivement la performance du modèle en ajoutant des arbres de décision, offrant une vitesse de calcul élevée et une capacité à traiter des ensembles de données volumineux

6.4.2 La validation croisée

La validation croisée est essentielle pour améliorer et tester notre modèle sans risquer le surapprentissage. En effet, pour réaliser une validation croisée, on divise tout d'abord nos données en données de test et données d'entraînement de la même manière que pour la classification et ensuite on va venir réaliser une validation croisée sur les données d'entraînement. On va entraîner notre modèle en cherchant les meilleurs paramètres puis on va tester notre modèle avec ces meilleurs paramètres sur nos données de test et observer le résultat.

La validation croisée consiste en la répétition de séparation des données en un groupe de test et un groupe d'entraînement pour améliorer les résultats, qu'ils soient plus fiable et permettent de surveiller le surapprentissage. Dans notre cas nous avons choisi de répéter ces tests 5 fois, donc de répartir les données en 5 découpage pour ainsi tout tester.

La validation croisée a également permis d'améliorer les paramètres des modèles en les testant sans risquer le surapprentissage. Notamment, après de nombreux tests de paramètres sur XGB Regressor qui avait les meilleurs résultats au départ, nous avons pu le faire performer d'environ 2

Les paramètres choisis étant donc les suivants : $\gamma=0.5$, $\text{learning_rate}=0.05$, $\text{max_depth}=9$, $n_estimators=500$, $\text{subsample}=0.7$.

6.4.3 Les variables d'importances

Après avoir établi notre modèle, l'avoir entraîné sur les données d'entraînement, il est temps de le tester sur nos données de test. En le testant ainsi, nous pouvons établir les variables d'importances qui vont permettre la prédiction et la détermination de la variable cible. Ces variables de plus grandes importances seront celles qui auront d'avantage d'impact dans la prédiction des résultats. On remarque ci-après l'histogramme pour XGB Regressor avec les meilleurs paramètres.




FIGURE 8 – Les variables d'importances à partir du meilleur modèle de XGBRegressor

On observe ainsi que les variables d'importances se retrouvent dans différentes catégories que ce soit lié au domaine du métier, au nom du métier, à l'état ou encore à d'autres critères. Ces critères d'importances sont souvent les mêmes entre les différents modèles mais leur pourcentage évolue.

6.4.4 Les résultats

Nous allons observer de la même manière que pour la classification, les résultats obtenus en prédiction sur un échantillon puis les paramètres de détermination et d'erreur quadratique obtenus.

TABLE 5 – Résultats de prédiction de la régression XGB Regressor

prédiction	réel
81275.52	81900.0
52551.95	65000.0
49337.156	46000.0
65703.086	76000.0
83179.516	90000.0

TABLE 6 – Résultat de la régression sur les 3 modèles

Paramètres	Linear Regression	Random Forest	XGB Regressor
Score r2	50.58%	48.11%	54.48%
Erreur mse	0.1014	0.1014	0.1014




FIGURE 9 – Résultats de la prédiction avec XGBRegressor

Les résultats obtenus montrent que le score R2 qui représente le coefficient de détermination du modèle renvoie un résultat moyen, mais qui reste intéressant. On remarque également que l'erreur quadratique moyenne est identique pour chacun des modèles et plutôt faible. On voit à partir du nuage de points que la régression effectuée reste plutôt satisfaisante, groupée avec peu de valeurs aberrantes.

7 Conclusion et améliorations

Pour conclure, les résultats obtenus que ce soit avec la régression ou avec la classification sont plus faibles que nous l'espérions. Nous avons pourtant tenté d'analyser au maximum les données dont nous disposons. Pour améliorer les résultats dans le futur et obtenir de meilleures prédictions, il serait possible de traiter d'avantage l'industrie et il serait utile d'ouvrir sur potentiellement d'autres données qui orienteraient d'avantage sur le salaire. En effet, les salaires sont très variables d'une personne à l'autre et même parfois pour le même travail et reste difficile à prédire, comme on peut le voir grâce à cette étude.